

가 장 가 까 운 1 0 0 쌍 찾 기

적벽대전

CSE244 Final Project

2018136153 최원홍
2015136133 최진우
2016136092 이상민
2017136008 권창덕

CONTENTS

01

문제 정의

- 문제 소개

02

설계 및 구현

- Parallel ver.1
- Parallel ver.2

03

결과 및 분석

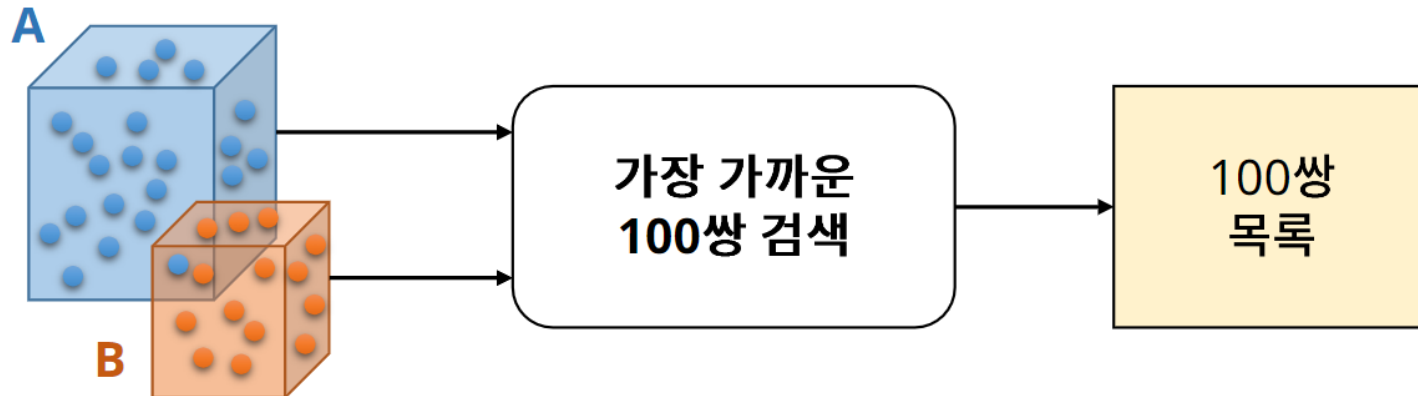
- 결과분석

01

문제 정의

01

문제 소개




입력 : A부대, B부대 (부대별 병사 수, x,y,z 좌표)

출력 : 피아식별하며, 가장 가까운 100쌍 목록


[IMG] https://koreatechackr-my.sharepoint.com/personal/bluekds_koreatech_ac_kr/_layouts/15/onedrive.aspx?id=%2Fpersonal%2Fbluekds%5Fkoreatech%5Fac%5Fkr%2FDocuments%2FEA%B0%95%EC%9D%98%2FEB%A9%80%ED%8B%B0%EC%BD%94%EC%96%B4%ED%94%84%EB%A1%9C%EA%B7%B8%EB%9E%98%EB%B0%8D%2F2022%5Fspring%2F%5FBMP%5D%20Project02%5FCUDA%2Epdf&parent=%2Fpersonal%2Fbluekds%5Fkoreatech%5Fac%5Fkr%2FDocuments%2FEA%B0%95%EC%9D%98%2FEB%A9%80%ED%8B%B0%EC%BD%94%EC%96%B4%ED%94%84%EB%A1%9C%EA%B7%B8%EB%9E%98%EB%B0%8D%2F2022%5Fspring&ga=1

01

문제 소개



(X)



(O)

단, **A부대** 기준으로 검색
(Euclidean distance 이용)

[IMG] https://koreatechackr-my.sharepoint.com/personal/bluekds_koreatech_ac_kr/_layouts/15/onedrive.aspx?id=%2Fpersonal%2Fbluekds%5Fkoreatech%5Fac%5Fkr%2FDocuments%2FEA%B0%95%EC%9D%98%2F%EB%A9%80%ED%8B%B0%EC%BD%94%EC%96%B4%ED%94%84%EB%A1%9C%EA%B7%B8%EB%9E%98%EB%B0%8D%2F2022%5Fspring%2F%5BMP%5D%20Project02%5FCUDA%2Epdf&parent=%2Fpersonal%2Fbluekds%5Fkoreatech%5Fac%5Fkr%2FDocuments%2FEA%B0%95%EC%9D%98%2F%EB%A9%80%ED%8B%B0%EC%BD%94%EC%96%B4%ED%94%84%EB%A1%9C%EA%B7%B8%EB%9E%98%EB%B0%8D%2F2022%5Fspring&ga=1

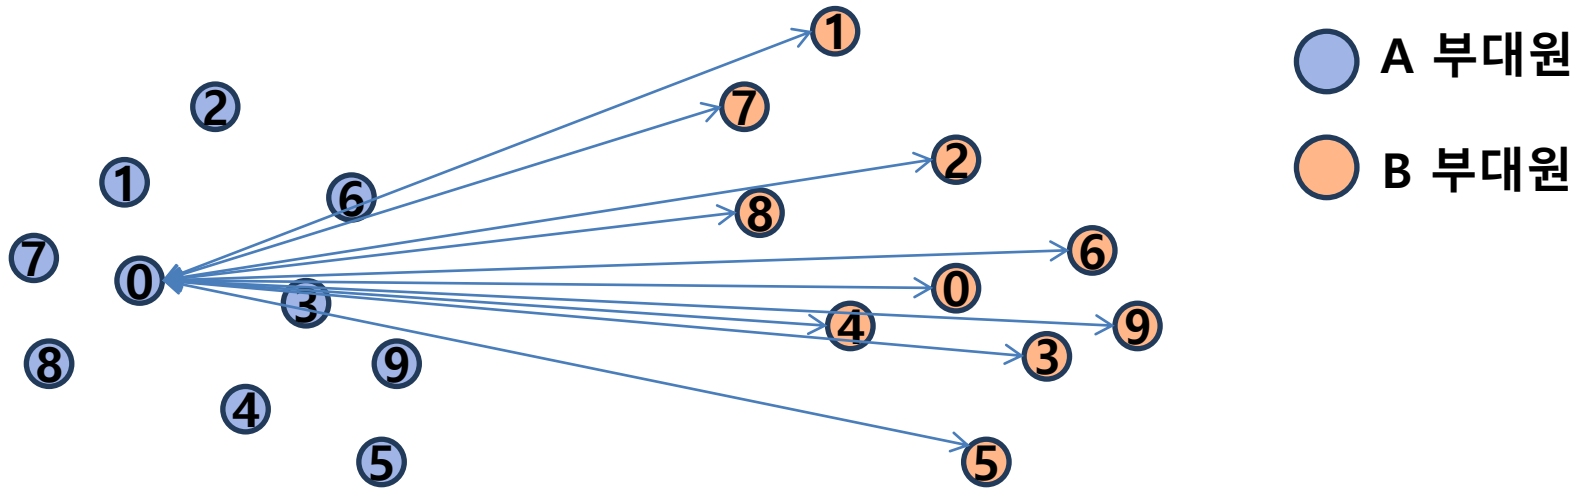
02

설계 및 구현

Parallel ver.1

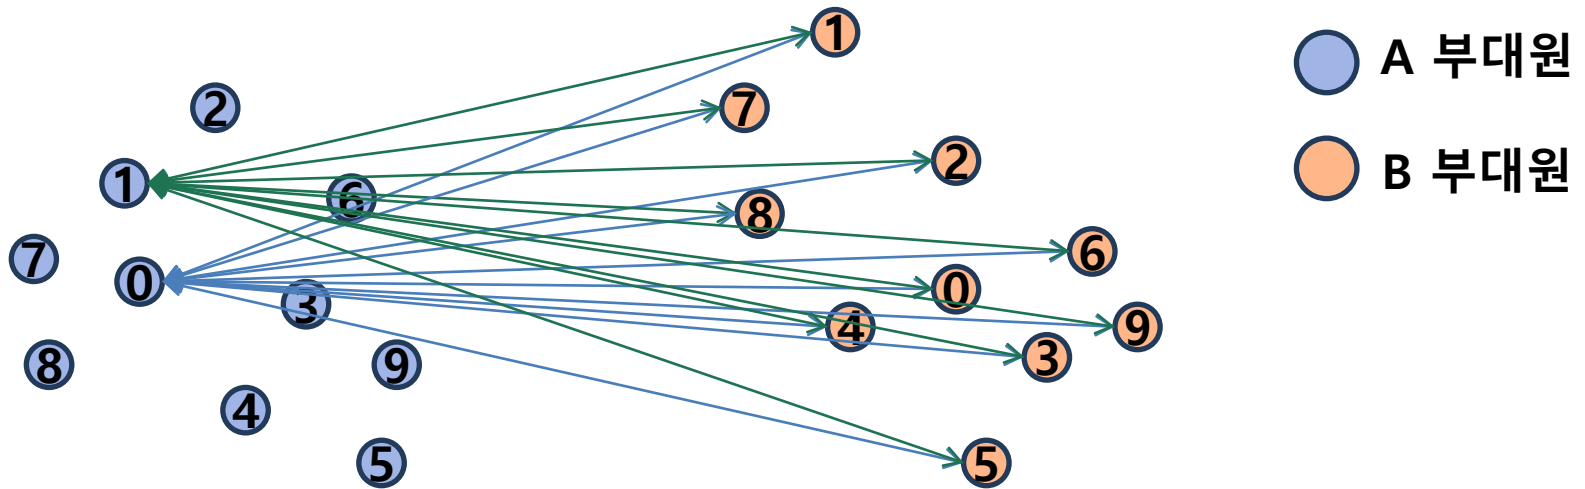
Brute-force

02


ver1. Idea

각 A부대원별, 모든 B부대원과의 거리를 계산하여, 최소거리인 B부대원을 찾음
한 A부대원당 총 B부대원 수만큼 매칭

02

ver1. Idea

A 수 = M
B 수 = N




$O(M*N)$
searching
*single thread

02


ver1. 구현

A부대원 수만큼
GPU Thread 생성



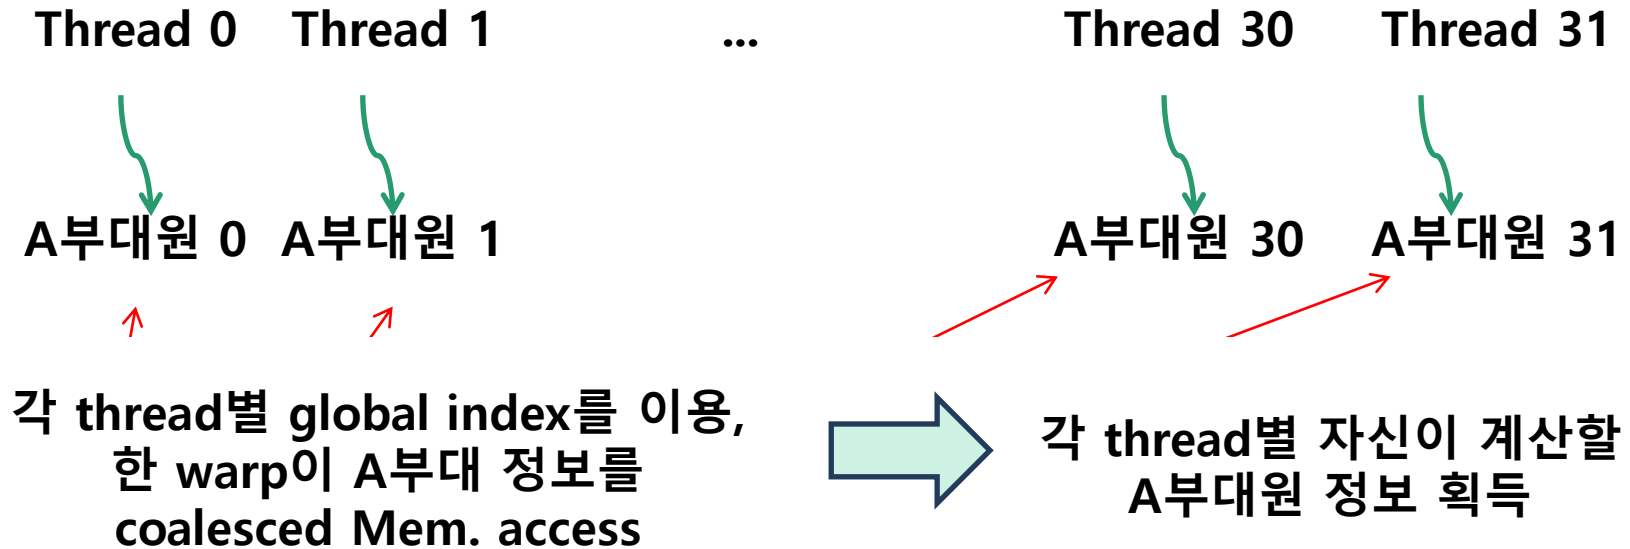
1D Grid & 1D Block
Block layout : (1024, 1, 1)
Grid layout : (ceil(M / 1024), 1, 1)

A 부대 정보
&
B 부대 정보



Global Memory
각 부대원 정보를
[XXX..., YYY..., ZZZ...]
형태로 저장

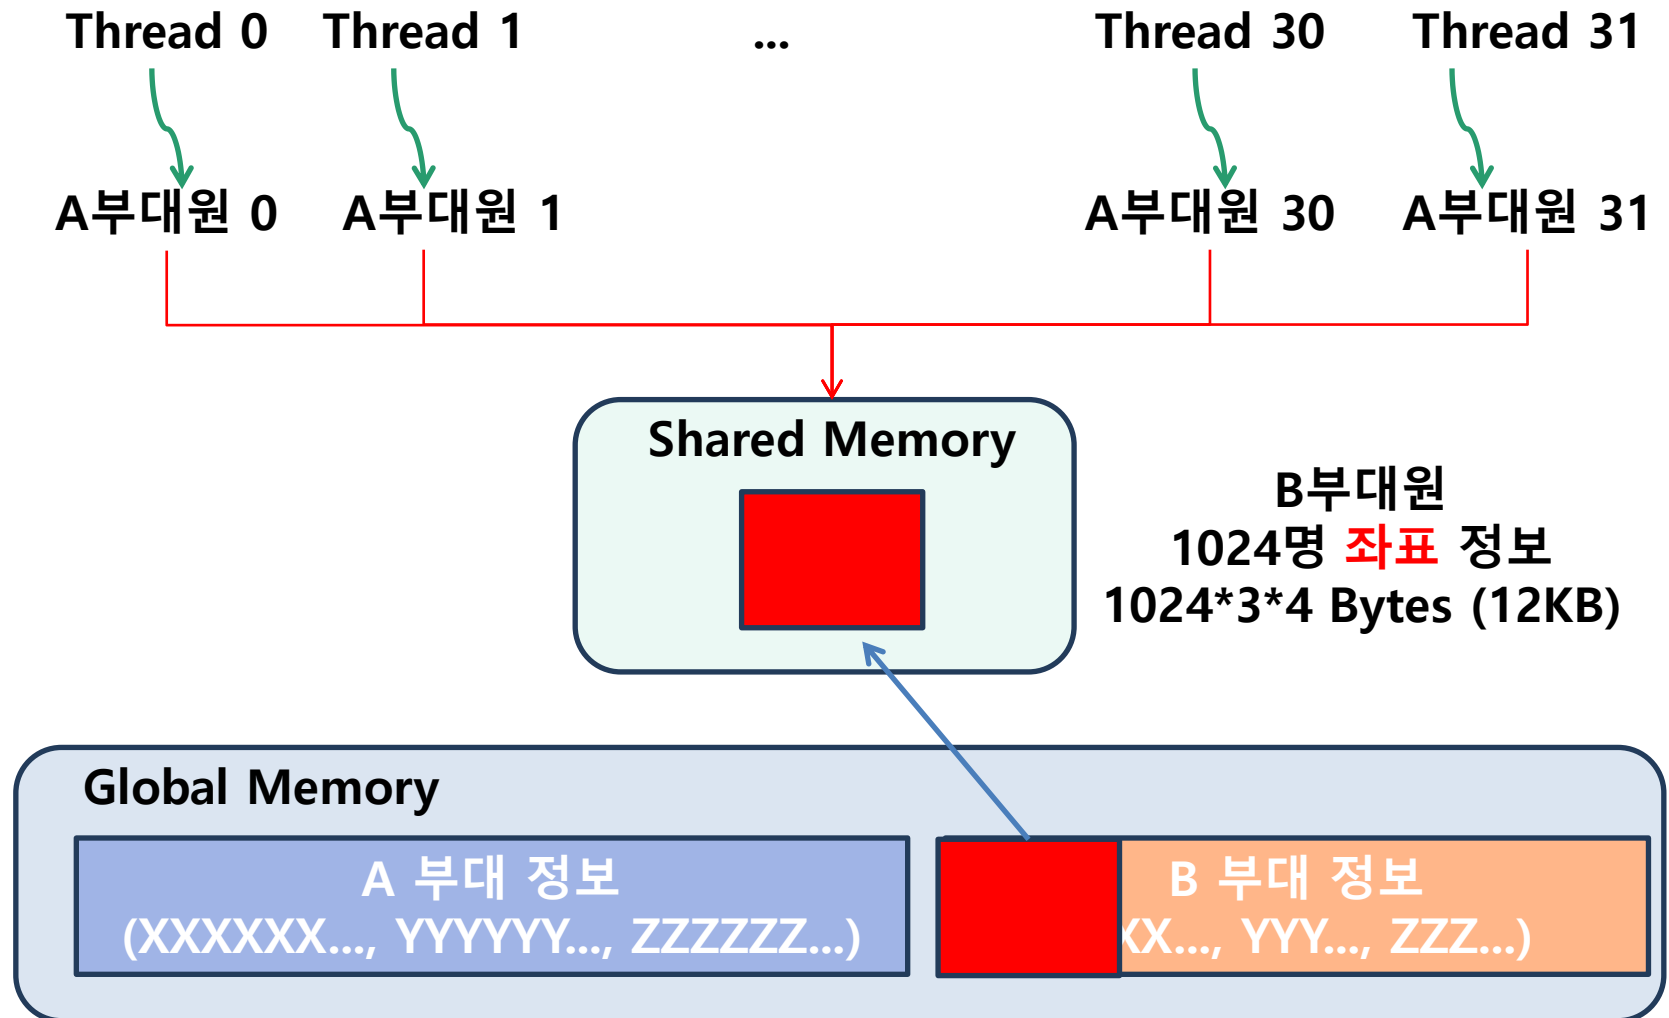
02

ver1. 구현~~Global Memory~~

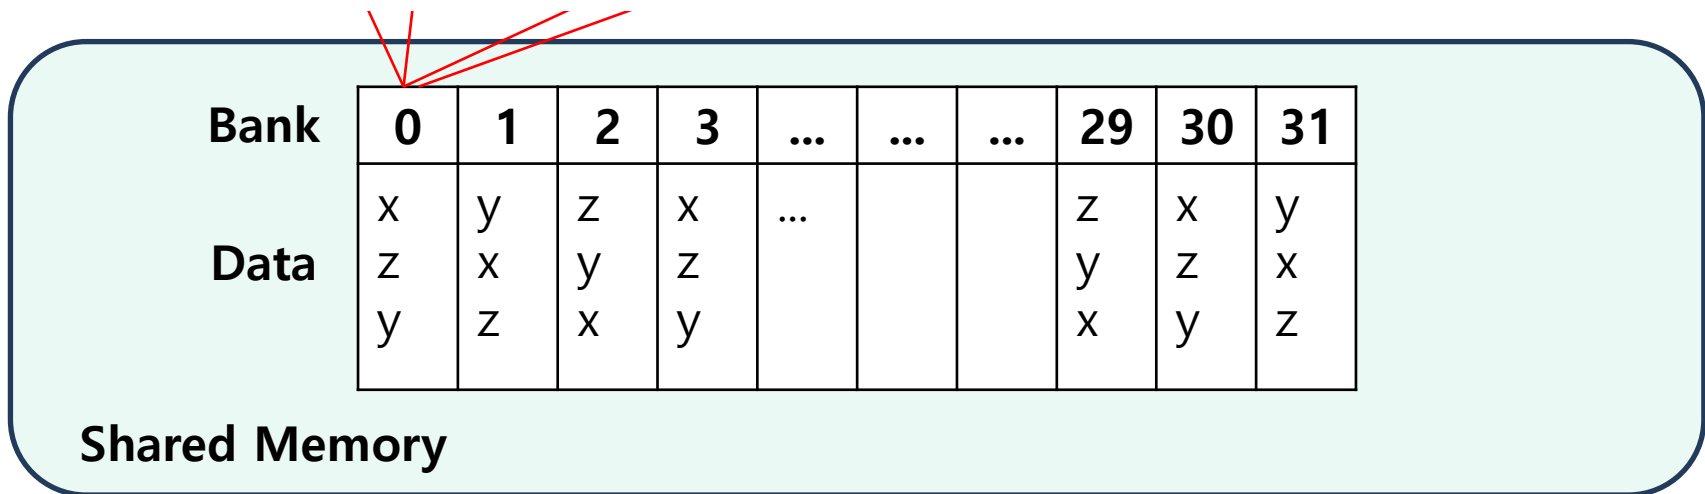

A 부대 정보
(XXXXXX..., YYYYYY..., ZZZZZZ...)

B 부대 정보
(XXX..., YYY..., ZZZ...)

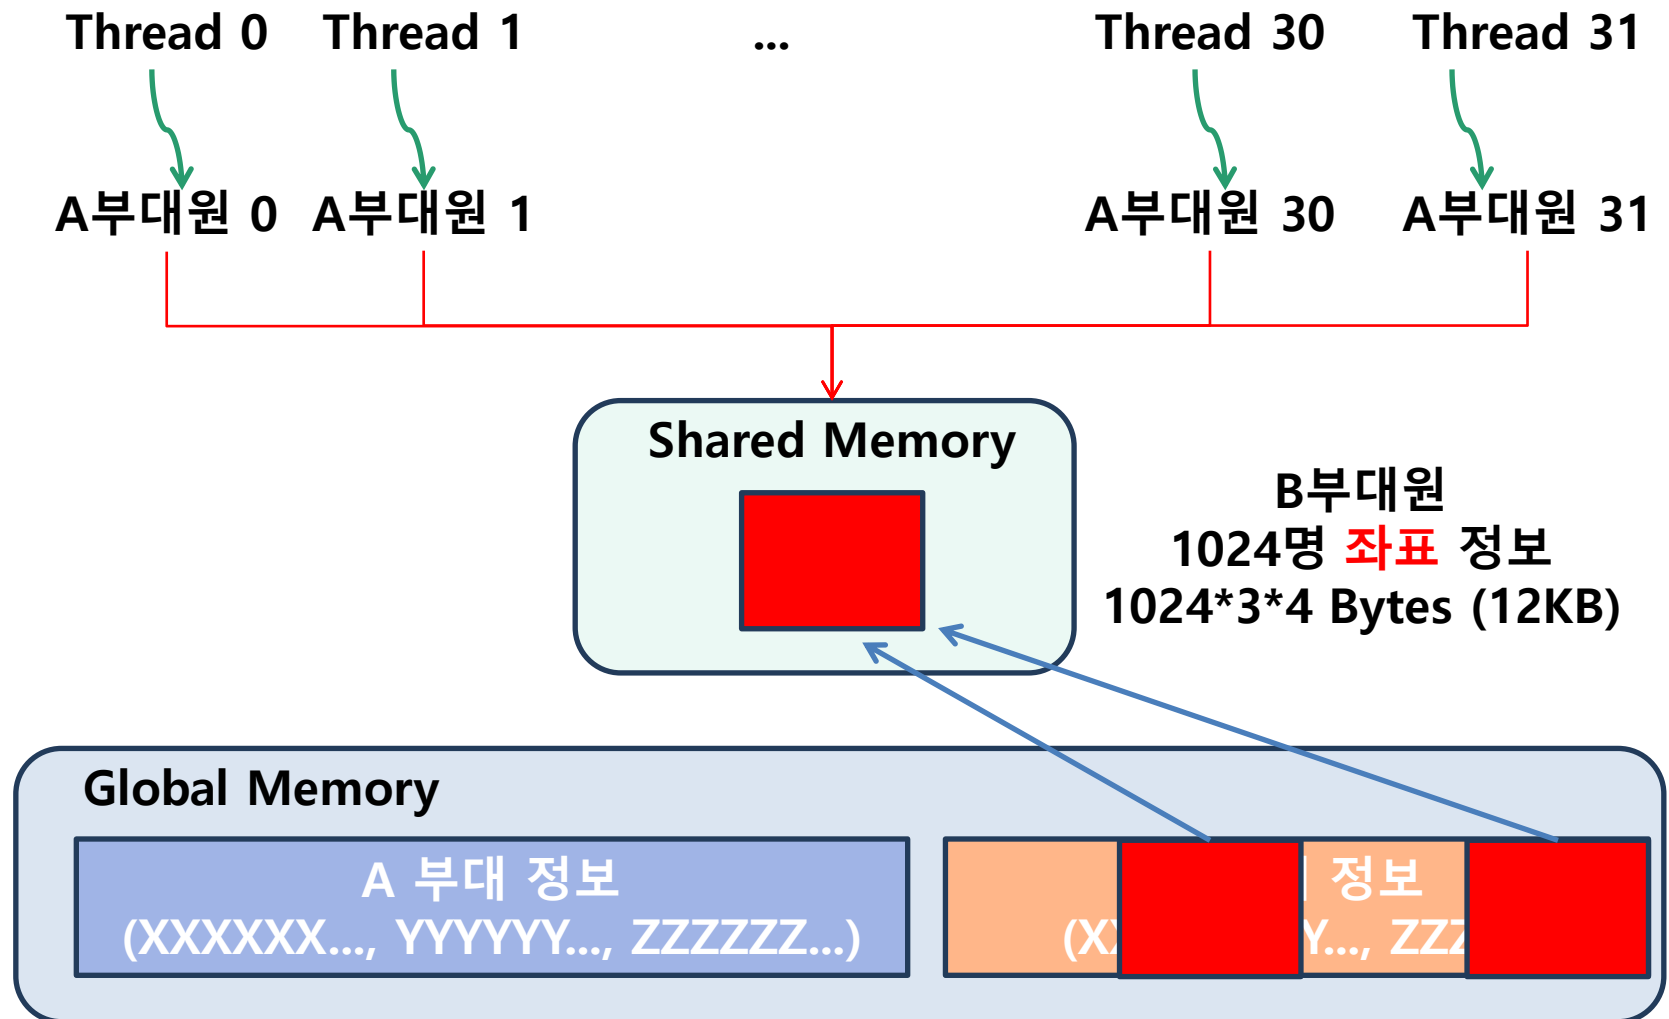
02

ver1. 구현

02

ver1. 구현

02

ver1. 구현

Parallel ver.2

Spatial Partitioning

02

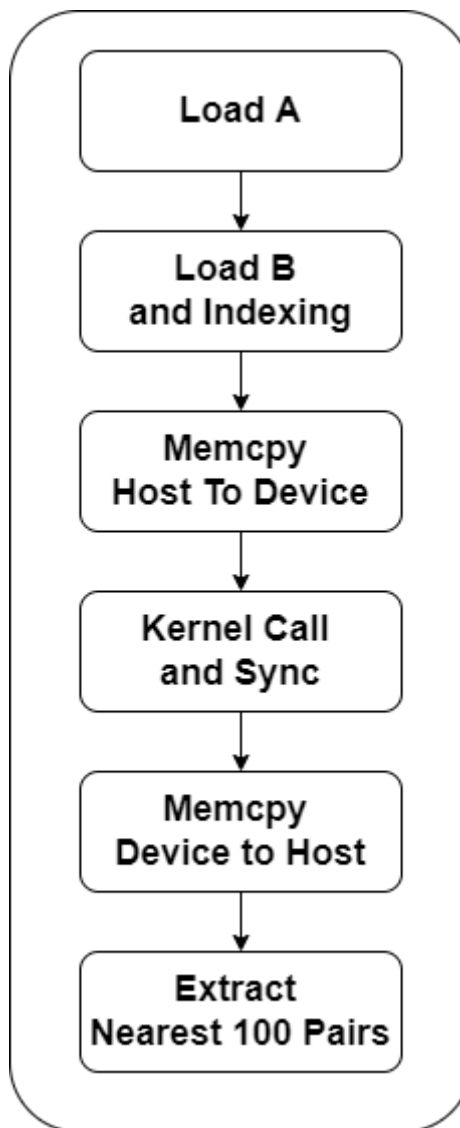
ver2. Motivation



[IMG] <http://kkoma.net/product/%ED%98%84%EC%88%98%EB%A7%89-%EB%B0%B0%EA%B2%BD3-%EB%B0%A4%ED%95%98%EB%8A%98-%EB%B3%84-%EC%97%B0%EA%B7%B9-%EA%B3%B5%EC%97%B0-%EB%AC%B4%EB%8C%80-%ED%8F%AC%ED%86%A0%EC%A1%B4-%EB%B0%B0%EA%B2%BD/6305/>


02

전체 흐름




**** kernel 외 전부 serial**

02

ver2. Idea

큐브 구조체 배열

< 전체 공간 >




큐브 구조체
- B의 갯수
- B 부대원(ID, 좌표) 배열

< 분할된 공간 >

각 B의 (x,y,z) 좌표를 이용해
큐브 구조체 배열(큐브 배열)에서 저장 위치(큐브)를 결정

02

ver2. Idea

● A 부대원

● B 부대원


만약, B의 수 = 25,

$$\sqrt{25} = 5,$$

각 축을 5등분
→ 전체 평면이
25등분됨

02

ver2. Idea




Army Generator →

* uniform int distribution

* RANGE MAX

이상적인 상황에서,
한 Tile 당 존재할 B의 수
의 기대값은 1개

02

ver2. Idea

● A 부대원

● B 부대원

만약, MAX=5이고,

한 A의 좌표가 (2.1, 2.1)이면,

$$X' = 2.1 / 1$$


$$Y' = 2.1 / 1$$

* 정수 나눗셈

이 A가 속한 타일의 인덱스
(X', Y') = (2, 2)

02

ver2. Idea



● A 부대원

● B 부대원


A가 속한 타일 내
B의 점과의 거리가 최소

하지만, 근처에 속한 타일
의 B의 점과 최소가 될 수
있음

따라서, A가 속한 타일과
주변의 타일을 검사할 필요
가 있음

02

ver2. Idea



● A 부대원

● B 부대원

다른 A부대원 역시
A가 속한 타일과 주변의
타일을 검사

25개의 B 중 5개만 검색

02

ver2. Idea

B의 수 = N


각 축을 $\sqrt[3]{N}$ 등분

→ 전체 공간 N 등분
(= N 개의 큐브)


큐브 모서리 길이
= $\text{RANGE_MAX} / \sqrt[3]{N}$

부대원 좌표 (x,y,z) 각각
큐브 모서리 길이로 정수 나눗셈


몫 → 해당 부대원이 존재하는
큐브 위치를 알 수 있음



A가 속한 큐브



주변 큐브




인접한 큐브를 포함
총 27개($3 \times 3 \times 3$)의 큐브
조사

02

ver2. Idea

총 27개(3x3x3) 큐브 내
B가 하나라도 존재하지 않으면,
가장 가까운 100쌍 내 속하지 않을 것으로 추정

02

ver2. Idea

● A 부대원

● B 부대원

0번은 검색 영역에 속하지만,
1번은 검색 영역에 속하지 않음
하지만, 1번 점과의 거리가 더 짧음

$100 \ll A$ 의 수


검색 영역 내 B가 하나 존재하고,
가장 멀리 떨어진 경우

* A: 100만, B: 40만 기준
큐브 모서리 길이 = 약 14,170
GT 100쌍 중 가장 큰 거리 = 395.30

02


ver2. Idea

A부대원 수만큼
GPU Thread 생성



1D Grid & 1D Block
Block layout : (1024, 1, 1)
Grid layout : (ceil(M / 1024), 1, 1)

A 부대 정보
&
B가 할당된 큐브 배열



Global Memory

각 Thread별
총 27개(3x3x3)의 큐브 search

가장 가까운 B ID, 거리를
자신의 register에 기록

02

ver2. Idea

	0	1	2		M-3	M-2	M-1
register	A: 0 B:2 dist: 255.44	A: 1 B:422 dist: 55.458	A: 2 B:53 dist: 312.1	...			A: M-1 B:489 dist: 321.97

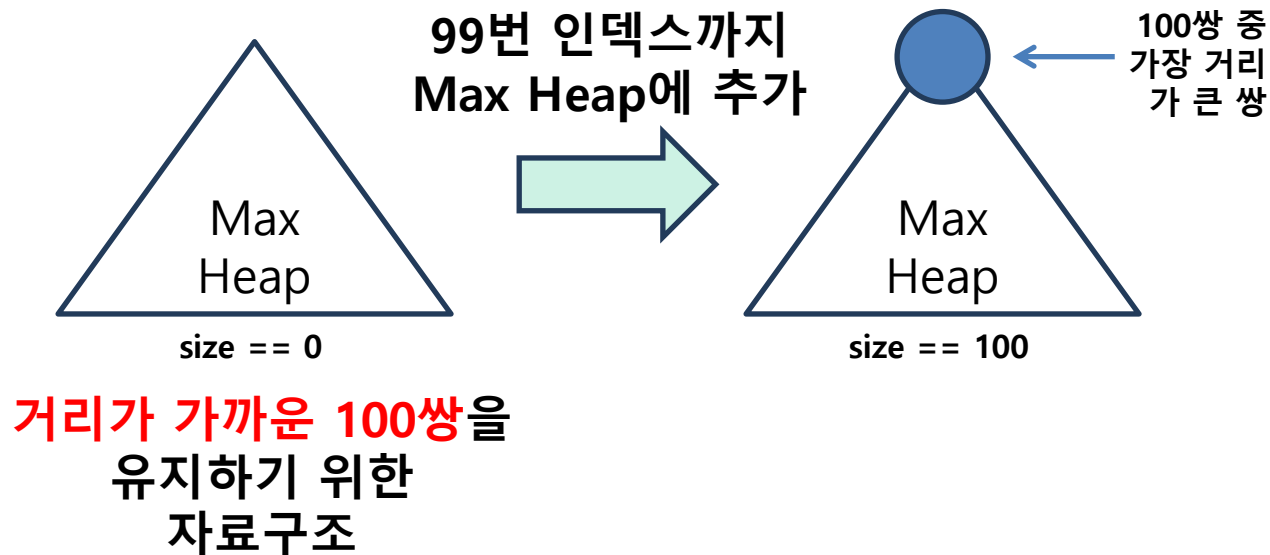



register → global mem.
memcpy (Device → Host)

	0	1	2		M-3	M-2	M-1
Host	A: 0 B:2 dist: 255.44	A: 1 B:422 dist: 55.458	A: 2 B:53 dist: 312.1	...			A: M-1 B:489 dist: 321.97


02

ver2. Idea




02

ver2. Idea



현재 순회 중인 원소의 거리가
Max Heap의 root 노드의
거리보다 작을 경우,

root 노드를 pop하고,
해당 원소를 push




최종 Max Heap엔
거리가 가까운 100쌍만 남음

02

ver2. Idea

Max Heap에 저장된 쌍 중
가장 거리가 큰 쌍



Max Heap을 pop하면서,
최종 결과 배열의 역순으로 저장

←

index	0	1	2		97	98	99
RESULT	A: 573 B:2 dist: 2.54	A: 521 B:422 dist: 5.458	A: 12 B:53 dist: 12.1	...			A: 1 B:489 dist: 321.97


03

결과 및 분석

03

결과 분석

실습 환경 : Ryzen 7 5800 X / RTX 2080 TI




03

결과 분석

실습 환경 : Ryzen 7 5800 X / RTX 2080 TI

* A 100만, B 40만 전체 실행시간



Parallel ver.1 (Brute-force)

약 587ms

Serial 대비 성능향상 약 1,850배

정확도 : 100%

Parallel ver.2 (Spatial Partitioning)

약 172ms

Serial 대비 성능향상 약 6,314배

정확도 : 100%

03

결과 분석

실습 환경 : Ryzen 7 5800 X / RTX 2080 TI

* A 100만, B 40만 전체 실행시간

* 단위 : ms

	1회	2회	3회	4회	5회	평균
Parallel ver.1	587.64890	594.12080	564.26280	585.85450	594.34940	585.2473
Parallel ver.2	172.96660	177.01230	173.69550	197.92030	205.06940	185.3328

평균 성능 기준 **약 3.16 배** 성능 향상

**THANK
YOU**

Shared memory bank conflicts



- Shared memory is as fast as registers if there are no bank conflicts
- Use the bank checker macro in the SDK to check for conflicts
 - warp_serialize signal can usually be used to check for conflicts
- The fast case:
 - If all threads of a half-warp access different banks, there is no bank conflict
 - If all threads of a half-warp read the identical address, there is no bank conflict (broadcast)
- The slow case:
 - Bank Conflict: multiple threads in the same half-warp access the same bank
 - Must serialize the accesses
 - Cost = max # of simultaneous accesses to a single bank